論文要約
「OASIS: Open Agent Social Interaction Simulations with One Million Agents」

f22123 5J-30 中村晴

参考文献

[1] Z. Yang ほか, 「Oasis: Open agent social interaction simulations with one million agents」, *arXiv preprint arXiv:2411.11581*, 2024, [Online]. 入手先: https://arxiv.org/abs/2411.11581

概要

- 従来のシナリオ特化型・小規模な LLM エージェントシミュレータの課題を解決するシステムの提案。
- 従来の研究は数百～数千人規模にとどまっていたが、現実の大規模な社会現象を再現するには不十分であった。
- X（旧 Twitter）や Reddit などの多様な SNS を再現可能な、汎用的かつ拡張性の高いシミュレータ「OASIS」を開発。
- 最大 100 万人規模の LLM エージェントによる大規模な社会相互作用の模擬実験を実現。
- 情報拡散の仕組み、集団極性化、同調現象などの現実世界の複雑な社会現象を忠実に再現可能。

OASIS の新規性

これまでの研究とは大きく異なる、OASIS の革新的な点は主に以下の 4 点です。

- 100 万人規模の模擬実験の実現。
  - 従来の人工知能を用いた実験は数百から数千人規模が限界でしたが、OASIS は現実の SNS に近い最大 100 万人の利用者を同時に動かすことに成功しました。
  - 単に数を増やしただけでなく、何百万もの処理要求を滞りなくさばく独自の推論システムを開発した点そのものが、技術的な大きな進歩です。
- 多様な交流サイトを再現できる高い汎用性。
  - 従来の仕組みは特定のサイトの実験に特化していましたが、OASIS は情報選別（推薦）の仕組みや行動の選択肢を柔軟に入れ替えることができます。
  - これにより、情報の流れが速い X（旧 Twitter）や、話題ごとに深く議論する Reddit など、全く構造が異なる環境をひとつのシステムで再現可能にしました。

- 現実世界のデータとの高い整合性の証明。
  - 現実の SNS の過去データと比較し、情報が広がる階層の深さや参加人数の規模を、非常に高い精度で再現できることを確認しました。
  - 単なる仮想の実験にとどまらず、現実社会の複雑な動きを予測・分析するための信頼できる道具として確立されています。
- 人数の規模が結果を変えることの実証（創発的特性の発見）。
  - 「少人数では明らかな嘘（デマ）に対する同調現象が起きてしまうが、1 万人規模になると集団による自己修正の動きが現れる」という事実を発見しました。
  - これは、人数の規模そのものが集団の行動を変化させることを証明しており、大規模な模擬実験を行うことの重要性を決定づけました。

手法

本論文の提案手法「OASIS」は、現実の SNS 構造を数学的およびシステム的に模倣した 5 つの主要な構成要素から成り立ちます。

1. 環境サーバー (Environment Server)

- ユーザーの基本情報、投稿の階層構造、およびフォロー関係などの膨大な関係網を効率的に保持するデータベースです。
- グラフ構造を用いて、ユーザーと投稿の関係性を隣接行列や木構造として管理し、情報の読み書きを高速化します。

2. 推薦システム (RecSys)

- エージェントの興味や過去の行動履歴から、次に見るべき最適な投稿を計算して提示する仕組みです。
- ユーザーの埋め込みベクトル E_u と投稿の埋め込みベクトル E_p の類似度に加え、投稿の「熱狂度（hotness）」を組み合わせて最終的な推薦スコア $S(u,p)$ を算出します。
- 推薦スコアの計算式は以下のように定式化されます。

$$S(u,p) = \alpha \cdot \mathrm{sim}\left(E_u, E_p\right) + (1-\alpha) \cdot \mathrm{hotness}(p)$$

（ここで、α は個人の興味と世間の流行のバランスを調整する重み係数です。）

3. エージェントモジュール (Agent Module)

- CAMEL を土台とし、性格や記憶を保持しながら自律的に行動を選択する部分です。
- 「投稿」「再投稿」「いいね」「フォロー」「無視」など 21 種類の多様な行動空間 A から、現在の状態 s_t と過去の記憶 M に基づいて最適な行動 a_t を確率的に選択します。
- 大規模言語モデルの推論を利用し、以下の条件付き確率を最大化する行動を決定します。

$$a_t = \mathrm{argmax}_{\{a \in A\}} P(a \mid s_t, M)$$

4. 時間管理エンジン (Time Engine)

- 全員が常に動くのではなく、人間の睡眠時間や活動の波を確率的に再現し、現実の時間の流れに合わせる仕組みです。
- 各時刻 t におけるエージェントの活動確率は、現実の SNS の統計データに基づく非定常ポアソン過程として数学的に表現されます。

$$P(N(t+\Delta t) - N(t) = 1) = \lambda(t)\Delta t + o(\Delta t)$$

（ここで、$\lambda(t)$ は時刻 t における活動の激しさを表す関数です。）

5. 大規模推論システム (Scalable Inferencer)

- 非同期メッセージキューと並行処理に対応した辞書を用いた通信経路により、毎秒発生する何万もの並行要求を滞りなく処理します。
- 記憶の重複を省く技術などを活用し、限られた計算資源を極限まで効率化することで、100 万人規模の推論を可能にしています。

6. 大規模ユーザー生成

- 現実の統計データに基づき、年齢、職業、性格などの属性を 100 万人に割り当てます。
- 中心的なユーザーと一般ユーザーを結びつけ、一部に繋がりが集中する現実のネットワーク特性を数学的に維持します。
- このネットワークの次数（つながりの数）k の分布は、以下のべき乗則に従うように生成されます。

$$P(k) \propto k^{-\gamma}$$

（現実の人間社会のネットワークと同様に、定数 γ は通常 $2 < \gamma < 3$ の範囲に設定されます。）

実験

本研究では、提案手法が現実の複雑な社会現象をどれほど正確に再現できるかを検証するため、主に 3 つの大規模な模擬実験を行いました。

1. X の基盤における情報拡散の再現

- 現実の X の過去データセット（Twitter15 および Twitter16）を基に、初期の投稿から情報が波及していく過程を木構造（ツリー構造）として再構築しました。
- 情報の広がり方を定量的に評価するため、情報の連鎖の「深さ（Depth）」、「最大幅（Max Breadth）」、および「総参加人数（Scale）」を主要な指標として計測しました。
- 現実のデータと模擬実験の結果の差異を相対誤差として算出し、システムが現実の拡散の法則性をどの程度模倣できているかを数学的に検証しました。

2. X の基盤における集団極性化の検証

- エージェント同士の議論によって意見が極端に振れる現象（集団極性化）を確認するため、倫理的ジレンマ（トロッコ問題など）を議題として与えました。
- 議論の前と後で各エージェントの意見（選択の確率）を測定し、集団全体の意見の偏りを分散 σ^2 などの統計量を用いて定量化しました。
- 特に、倫理的な安全制限を外した人工知能モデルを用いた場合と、制限のあるモデルを用いた場合とで、意見の過激化の進行度合いを比較しました。

3. Reddit の基盤における同調現象の検証

- 人間が他者の評価に引きずられる「同調現象」を再現するため、Reddit のコメント環境を模した対照実験を設計しました。
- 明らかな嘘（反事実）を含む投稿に対し、「初期に低評価を多数与える群」、「初期に高評価を多数与える群」、「操作を行わない群（対照群）」の 3 条件を用意しました。
- エージェントが嘘に対して反論する度合いを「反対スコア（Disagree Score）」として数値化し、自身の信念と、観測された他者の評価（社会的シグナル）が意思決定に与える影響を比較評価しました。

4. 100 万人規模での情報伝播の比較実験

- 最大規模の実験設定として、100 万人のエージェントが活動する仮想空間に、公式ニュースと偽情報（デマ）をそれぞれ同時に投入しました。
- 情報を発信した直後から数日間にわたる時間経過 t に伴い、各情報に対する「関連投稿の総数」や「ユーザー間のつながりの変化」を継続的に追跡する仕組みを構築しました。

結果

X の基盤における情報拡散の精度

- 模擬実験で生成された情報伝播の木構造と、現実のデータセット（Twitter15/16）を比較した結果、高い再現性が確認されました。
- 情報の「深さ（Depth）」の相対誤差はわずか約 1.5%、「最大幅（Max Breadth）」は約 17%、「総参加人数（Scale）」は約 34% にとどまり、現実の複雑な情報の広がりを極めて正確に模倣できていることが証明されました。

X の基盤における集団極性化

- 倫理的ジレンマに関する議論において、対話の回数（ラウンド）を重ねるごとに意見の分布が両極端に分かれる「集団極性化」が確認されました。
- 特に、安全制限が施されていない人工知能モデルの集団では、意見の分散が議論の初期段階から急速に増大し、対立が先鋭化しやすいことが定量的（数値的）に示されました。

Reddit の基盤における同調現象

- 初期に意図的に「低評価」を集中させた群では、エージェントがその場の空気に流され、自らも低評価を下す確率が有意に上昇しました。
- 明らかな嘘（反事実）に対しても、人間の集団と同様に周囲の評価に引きずられてしまい、反対意見を述べる度合い（Disagree Score）が低下する強い同調現象が確認されました。

エージェント数の規模による影響

- 実験に参加する人工知能の数を 196 人、1,000 人、10,000 人と段階的に増やすことで、集団の振る舞いがどのように変化するか（規模の効果）を検証しました。
- 人数が増加するにつれて、集団内で生成される意見や解決策の多様性が増し、より多角的な視点が得られることが確認されました。
- 自浄作用の発生: 少人数の実験では明らかな嘘がそのまま受け入れられてしまいましたが、10,000 人規模に達すると、集団の一部が自発的に「それは事実ではない」と指摘し始め、デマを訂正・抑制する「自己修正の動き」が生まれることが発見されました。

結果（100 万人規模のシミュレーション）

100 万人規模の環境で、公式ニュースと偽情報（デマ）の拡散過程を比較しました。

- 影響力の大きさ: 偽情報は公式ニュースと比較して、より多くの再投稿や引用を誘発し、情報の連鎖がより深く、広範囲に及ぶことが確認されました。
- 持続性の違い: どちらの情報も初期に爆発的に拡散した後、時間経過とともに注目度は低下（減衰）します。しかし、公式ニュースが急速に忘れ去られるのに対し、偽情報に関する議論は後半になっても高い活動水準を維持し、長期的な影響力を持ち続けることが判明しました。
- 集団の形成: 偽情報を巡る議論の過程で、エージェント間の関係網を分析した結果、同じ意見を持つ者同士が密に繋がり、外部の意見を遮断する「反響室（閉鎖的な言論空間）」に類似した集団が自然に形成される様子が観察されました。

構成要素の検証

OASIS の各構成要素が欠けた場合にどうなるかを検証（アブレーション調査）。

- 推薦システムの有無
  - 推薦システムがないと、情報がごく限られた範囲でしか伝わらず、社会全体への爆発的な情報の拡散が阻害され、実験自体が成立しにくくなる。
- 埋め込みモデルの比較
  - 一般的な文章解析の手法よりも、SNS の繋がりを学習することに特化した手法（TwHIN-BERT）の方が、エージェントの興味に沿った適切な推薦が可能。
- 時間的特徴の検証
  - 人間の活動時間を模した確率設定を除外すると、全員が同時に行動を起こしてしまい、現実世界でみられる「数日かけて徐々に波及する」という伝播の波を正確に再現できなくなる。

限界と社会的影響・結論

- 結論として、OASIS は様々な基盤に適応可能で、100 万人規模の複雑な社会相互作用を精密に分析できる強力な道具である。
- 提案手法の限界
  - 推薦システムは高度な模倣であるが、より複雑な計算手法は未実装であり、これが現実とのわずかな差異の一因となっている。
  - 画像や動画などを含む複合的な情報には未対応である。
- 社会的影響と倫理的配慮
  - 現実のデータを用いてエージェントを学習させる際、個人情報の保護と匿名性の確保が強く求められる。
  - 100 万人規模の強力な模擬実験システムは、悪用されれば世論操作やデマ拡散の手口を洗練させる道具になり得るため、厳格な倫理基準に基づく運用が不可欠である。

単語リスト

No.	単語	意味	例文	意味
1	advancement	進歩，発展	The rapid advancement of chat-based language models has led to remarkable progress.	チャットベースの言語モデルの急速な進歩は，目覚ましい進展をもたらした．
2	remarkable	注目すべき，目覚ましい	...has led to remarkable progress in complex task-solving.	...複雑なタスク解決において目覚ましい進歩をもたらした．
3	autonomous	自律的な	Facilitate autonomous cooperation among communicative agents.	通信エージェント間の自律的な協力を促進する．
4	communicative	意思疎通のできる，通信の	Facilitate autonomous cooperation among communicative agents.	通信エージェント間の自律的な協力を促進する．
5	cognitive	認知の	Provide insight into their "cognitive" processes.	彼らの「認知」プロセスへの洞察を提供する．
6	framework	枠組み，フレームワーク	We propose a novel communicative agent framework named role-playing.	ロールプレイングと名付けられた新しい通信エージェントの枠組みを提案する．
7	inception	開始，（ここでは）初期指示	Our approach involves using inception prompting to guide chat agents.	我々の手法は，チャットエージェントを誘導するために初期指示プロンプトを使用する．

8	consistency	一貫性	Maintaining consistency with human intentions.	人間の意図との一貫性を維持する.
9	intention	意図	Maintaining consistency with human intentions.	人間の意図との一貫性を維持する.
10	behavioral	行動の	Studying the behaviors and capabilities of a society of agents.	エージェント社会の行動と能力を研究する.
11	capability	能力	Studying the behaviors and capabilities of a society of agents.	エージェント社会の行動と能力を研究する.
12	investigation	調査，研究	Providing a valuable resource for investigating conversational language models.	対話型言語モデルを調査するための貴重なリソースを提供する.
13	instruction-following	指示に従うこと	Conduct comprehensive studies on instruction-following cooperation.	指示に従う協力に関する包括的な研究を行う.
14	contribution	貢献	Our contributions include introducing a novel communicative agent framework.	我々の貢献には，新しい通信エージェントの枠組みの導入が含まれる.
15	intelligence	知能	What magical trick makes us intelligent?	どんな魔法の仕掛けが私たちを知的にするのか？
16	stem	生じる，由来する	The power of intelligence stems from our vast diversity.	知能の力は，私たちの膨大な多様性から生じている.

17	diversity	多様性	The power of intelligence stems from our vast diversity.	知能の力は，私たちの膨大な多様性から生じている．
18	principle	原則，原理	...not from any single, perfect principle.	...単一の完璧な原則からではない．
19	complexity	複雑さ	Confronted with the complexities of real-world tasks.	現実世界のタスクの複雑さに直面している．
20	achievement	達成，成果	...has yielded remarkable achievements in complex task-solving.	...複雑なタスク解決において目覚ましい成果を挙げている．
21	reliance	依存，信頼	Their success is heavily reliant on human input.	彼らの成功は人間の入力に大きく依存している．
22	guidance	誘導，指導	...human input to guide the conversation in the right direction.	...会話を正しい方向に誘導するための人間の入力．
23	expertise	専門知識	Crafting effective prompts often demands a deep understanding and expertise.	効果的なプロンプトを作成するには，深い理解と専門知識が必要な場合が多い．
24	domain	領域	...expertise of a particular domain of knowledge.	...特定の知識領域の専門知識．
25	predicament	苦境，窮地	This predicament is raising a crucial question.	この苦境は重大な疑問を投げかけている．

26	intervention	介入	Can we replace human intervention with an autonomous communicative agent?	人間の介入を自律的な通信エージェントに置き換えることはできるか？
27	steering	操縦，方向付け	...capable of steering the conversation toward task completion.	...会話をタスク完了へと導くことができる．
28	supervision	監督	...with minimal human supervision.	...最小限の人間の監督で．
29	anticipate	予測する	Important for anticipating the future of artificial intelligence.	人工知能の未来を予測するために重要である．
30	dynamics	力学，動態	The dynamics of collaborating or competing agents play a key role.	協力または競合するエージェントの動態が重要な役割を果たす．
31	facilitate	促進する	Build scalable techniques to facilitate autonomous cooperation.	自律的な協力を促進するためのスケーラブルな技術を構築する．
32	align	調整する，合わせる	Ways to align these models with human intentions.	これらのモデルを人間の意図に合わせる方法．
33	modular	モジュール式の	Our library provides modular functionality.	我々のライブラリはモジュール式の機能を提供する．
34	implementation	実装	...includes implementations of different agents.	...異なるエージェントの実装を含んでいる．
35	scalable	拡張性のある	Provide a highly scalable way to generate conversational data.	対話データを生成するための非常に拡張性の高い方法を提供する．

36	scenario	シナリオ，場面	In particular, we consider two cooperative scenarios.	特に，2 つの協力シナリオを検討する．
37	misalignment	ずれ，不整合	Generate a Misalignment dataset that is a simulation of possible malicious applications.	起こりうる悪意のあるアプリケーションのシミュレーションである不整合データセットを生成する．
38	simulation	シミュレーション	...that is a simulation of possible malicious applications.	...それは起こりうる悪意のあるアプリケーションのシミュレーションである．
39	malicious	悪意のある	...a simulation of possible malicious applications.	...起こりうる悪意のあるアプリケーションのシミュレーション．
40	unaligned	調整されていない	...potential risks of an unaligned autonomous agent system.	...調整されていない自律エージェントシステムの潜在的なリスク．
41	comprehend	理解する	Enabling them to comprehend and react to human language.	彼らが人間の言語を理解し，反応できるようにする．
42	enhance	強化する	...can potentially enhance the development of more advanced language models.	...より高度な言語モデルの開発を強化する可能性がある．
43	outperform	上回る	...outperform those generated in a single shot by gpt-3.5-turbo.	...gpt-3.5-turbo によるシングルショットで生成されたものを上回る．

44	emergence	出現，（ここでは）創発	We also study knowledge emergence in LLMs.	LLM における知識の創発についても研究する．
45	fine-tuning	微調整	...by fine-tuning LLaMA on progressively growing datasets.	...段階的に増加するデータセットで LLaMA を微調整することによって．
46	benchmark	指標，ベンチマーク	...through benchmarking our final model on HumanEval.	...HumanEval で最終モデルをベンチマークすることによって．
47	competitive	競争力のある，（ここでは）匹敵する	...we show competitive pass@k scores with LLaMa-7B.	...LLaMa-7B と遜色のない pass@k スコアを示す．
48	adhere	遵守する	Al systems adhere to their intended goals.	AI システムは意図された目標を遵守する．
49	descriptive	記述的な	...provides a detailed description to make the idea specific.	...アイデアを具体的にするための詳細な記述を提供する．
50	instantiate	具体化する，例示する	The role-playing session will be instantiated from an idea.	ロールプレイングセッションはアイデアから具体化される．
51	designate	指定する	...only to designate the potential roles.	...潜在的な役割を指定するだけでよい．
52	interact	相互作用する	Engaging in interactive planning to determine feasible steps.	実行可能なステップを決定するための対話的な計画に関与する．

53	feasible	実行可能な	...to determine feasible steps for the AI assistant to execute.	...AI アシスタントが実行するための実行可能なステップを決定する.
54	historical	過去の	...takes the historical conversation message set.	...過去の会話メッセージセットを受け取る.
55	termination	終了	...communication protocols, termination conditions, and constraints.	...通信プロトコル，終了条件，および制約.
56	protocol	プロトコル，規約	...communication protocols, termination conditions.	...通信プロトコル，終了条件.
57	constraint	制約	...termination conditions, and constraints or requirements.	...終了条件，および制約や要件.
58	deviation	逸脱	...avoiding any deviation from the structure of the conversation.	...会話の構造からの逸脱を避ける.
59	symmetry	対称性	...strive to maintain as much symmetry as possible.	...可能な限り対称性を維持するよう努める.
60	sophisticated	洗練された	...develop an increasingly sophisticated understanding of these domains.	...これらの領域に対するますます洗練された理解を深める.