論文要約

「OASIS: Open Agent Social Interaction Simulations with One Million Agents」

学籍番号 名前

Reference

Abstract

- 従来のシナリオ特化型・小規模な LLM エージェントシミュレータの課題を解決するシステムの提案
- X（旧 Twitter）や Reddit などの多様な SNS を再現可能な、汎用的かつ拡張性の高いシミュレータ「OASIS」を開発
- 最大 100 万人規模の LLM エージェントによる大規模な社会相互作用のシミュレーションを実現
- 情報拡散、集団極性化、同調現象（ハード効果）などの現実世界の社会現象を忠実に再現可能

Methods

- 本論文の提案手法「OASIS」は、現実の SNS 構造に基づいた 5 つの主要な構成要素から成り立つ
  - Environment Server: ユーザー情報、投稿、関係性を管理するデータベース
  - RecSys (推薦システム): エージェントの興味や流行に基づく情報選別
  - Agent Module: CAMEL を土台とした、記憶と行動（21 種類）を制御する部分
  - Time Engine: 現実の活動確率に基づく時間管理と作動
  - Scalable Inferencer: 大規模推論を可能にする非同期処理・GPU 管理システム

図 2: OASIS の処理の流れ (画像省略)

Scalable Design (大規模化への工夫)

- 大規模なエージェントを動作させるための 2 つの重要な工夫
- Scalable Inference (大規模推論システム)
  - 非同期メッセージキューとスレッドセーフな辞書を用いた通信経路により、並行要求を処理
  - GPU リソースを管理し、推論要求を効率的に分散
- Large-scale User Generation (大規模ユーザー生成)
  - 人口統計データ（年齢、性格など）と興味関心に基づくネットワーク生成モデルを組み合わせ、最大 100 万人のユーザーを生成
  - 中心的なユーザーと一般ユーザーを結びつけ、スケールフリーなネットワーク特性を維持

Experiments

検証の対象は、X における情報拡散と Reddit における同調現象、および大規模環境での偽情報拡散

Information Propagation in X (情報拡散と集団極性化)

- 現実の X のデータセット（Twitter15/16）を使用し、情報伝播の規模と深さを比較
- ジレンマに対するエージェントの意見変化を観察し、集団極性化を評価

Herd Effect in Reddit (同調現象)

- 現実の Reddit コメントを使用し、「初期に低評価」「初期に高評価」などの条件下での反応を評価
- 反事実（偽情報）に対するエージェントの反論度合い（Disagree Score）を測定

Results

X の基盤での結果

- 情報拡散の規模（Scale）と最大幅（Max Breadth）は現実世界の傾向を正確に再現
- 議論を重ねるごとに意見が極端になる「集団極性化」を確認（特に安全制限のないモデルで顕著）

Reddit の基盤での結果

- エージェントは人間よりも、初期の低評価に流されやすい（同調現象が強い）傾向がある

Agent 数の規模による影響 (Scale Effect)

- 人数が増えるほど（196 人 → 数万人）、意見の多様性が増し、より役立つ回答が得られる

- 反事実に対する同調現象は少人数では起きないが、1 万人規模になると明確に発生し、集団による自己修正の動きも現れる

Results (1 Million Agents Simulation)

100 万人規模での公式ニュースと偽情報（Misinformation）の拡散比較

- 偽情報の影響力は公式ニュースよりも一貫して大きい
- どちらも初期に爆発的に関連投稿が増えるが、時間経過で減少する
- 偽情報に関する投稿は後半になっても高い活動水準を維持し、持続的な影響力を持つ
- シミュレーションの過程で、エージェント間に新たな集団（クラスタ）が形成される現象を確認

図 9: 偽情報と公式ニュースの拡散比較 (画像省略)

Ablation Studies

OASIS の各構成要素の有効性を評価

- RecSys (推薦システム) の有無
  - 推薦システムがないと情報の拡散が著しく阻害され、シミュレーションが成立しにくくなる
- 埋め込みモデルの比較
  - 一般的な手法よりも、SNS に特化した TwHIN-BERT の方が適切な推薦が可能
- Temporal Feature (時間的特徴) の検証
  - 現実に基づく活動確率（時間帯ごとの活発さ）を除外すると、現実世界の伝播の傾向を正確に再現できなくなる

Limitation & Conclusion

- OASIS は様々な基盤に適応可能で、100 万人規模の相互作用を支える強力な道具である
- 提案手法の限界
  - 推薦システムは高度な模倣であり、協調フィルタリングのような複雑な計算手法は未実装（現実との差異の一因）
  - ブックマーク、投げ銭、ライブ配信などの機能は未対応
  - 文章情報のみの環境であり、画像や動画の複合的な情報は未対応
  - 100 万人規模のシミュレーションには数日を要するため、推論とデータベース効率の最適化が今後の課題

Word List

No.	単語	意味	例文	意味
1	advancement	進歩，発展	The rapid advancement of chat-based language models has led to remarkable progress.	チャットベースの言語モデルの急速な進歩は，目覚ましい進展をもたらした．
2	remarkable	注目すべき，目覚ましい	...has led to remarkable progress in complex task-solving.	...複雑なタスク解決において目覚ましい進歩をもたらした．
3	autonomous	自律的な	Facilitate autonomous cooperation among communicative agents.	通信エージェント間の自律的な協力を促進する．
4	communicative	意思疎通のできる，通信の	Facilitate autonomous cooperation among communicative agents.	通信エージェント間の自律的な協力を促進する．
5	cognitive	認知の	Provide insight into their "cognitive" processes.	彼らの「認知」プロセスへの洞察を提供する．
6	framework	枠組み，フレームワーク	We propose a novel communicative agent framework named role-playing.	ロールプレイングと名付けられた新しい通信エージェントの枠組みを提案する．
7	inception	開始，（ここでは）初期指示	Our approach involves using inception prompting to guide chat agents.	我々の手法は，チャットエージェントを誘導するために初期指示プロンプトを使用する．

8	consistency	一貫性	Maintaining consistency with human intentions.	人間の意図との一貫性を維持する.
9	intention	意図	Maintaining consistency with human intentions.	人間の意図との一貫性を維持する.
10	behavioral	行動の	Studying the behaviors and capabilities of a society of agents.	エージェント社会の行動と能力を研究する.
11	capability	能力	Studying the behaviors and capabilities of a society of agents.	エージェント社会の行動と能力を研究する.
12	investigation	調査，研究	Providing a valuable resource for investigating conversational language models.	対話型言語モデルを調査するための貴重なリソースを提供する.
13	instruction-following	指示に従うこと	Conduct comprehensive studies on instruction-following cooperation.	指示に従う協力に関する包括的な研究を行う.
14	contribution	貢献	Our contributions include introducing a novel communicative agent framework.	我々の貢献には，新しい通信エージェントの枠組みの導入が含まれる.
15	intelligence	知能	What magical trick makes us intelligent?	どんな魔法の仕掛けが私たちを知的にするのか？
16	stem	生じる，由来する	The power of intelligence stems from our vast diversity.	知能の力は，私たちの膨大な多様性から生じている.

17	diversity	多様性	The power of intelligence stems from our vast diversity.	知能の力は，私たちの膨大な多様性から生じている．
18	principle	原則，原理	...not from any single, perfect principle.	...単一の完璧な原則からではない．
19	complexity	複雑さ	Confronted with the complexities of real-world tasks.	現実世界のタスクの複雑さに直面している．
20	achievement	達成，成果	...has yielded remarkable achievements in complex task-solving.	...複雑なタスク解決において目覚ましい成果を挙げている．
21	reliance	依存，信頼	Their success is heavily reliant on human input.	彼らの成功は人間の入力に大きく依存している．
22	guidance	誘導，指導	...human input to guide the conversation in the right direction.	...会話を正しい方向に誘導するための人間の入力．
23	expertise	専門知識	Crafting effective prompts often demands a deep understanding and expertise.	効果的なプロンプトを作成するには，深い理解と専門知識が必要な場合が多い．
24	domain	領域	...expertise of a particular domain of knowledge.	...特定の知識領域の専門知識．
25	predicament	苦境，窮地	This predicament is raising a crucial question.	この苦境は重大な疑問を投げかけている．

26	intervention	介入	Can we replace human intervention with an autonomous communicative agent?	人間の介入を自律的な通信エージェントに置き換えることはできるか？
27	steering	操縦，方向付け	...capable of steering the conversation toward task completion.	...会話をタスク完了へと導くことができる．
28	supervision	監督	...with minimal human supervision.	...最小限の人間の監督で．
29	anticipate	予測する	Important for anticipating the future of artificial intelligence.	人工知能の未来を予測するために重要である．
30	dynamics	力学，動態	The dynamics of collaborating or competing agents play a key role.	協力または競合するエージェントの動態が重要な役割を果たす．
31	facilitate	促進する	Build scalable techniques to facilitate autonomous cooperation.	自律的な協力を促進するためのスケーラブルな技術を構築する．
32	align	調整する，合わせる	Ways to align these models with human intentions.	これらのモデルを人間の意図に合わせる方法．
33	modular	モジュール式の	Our library provides modular functionality.	我々のライブラリはモジュール式の機能を提供する．
34	implementation	実装	...includes implementations of different agents.	...異なるエージェントの実装を含んでいる．
35	scalable	拡張性のある	Provide a highly scalable way to generate conversational data.	対話データを生成するための非常に拡張性の高い方法を提供する．

36	scenario	シナリオ，場面	In particular, we consider two cooperative scenarios.	特に，2 つの協力シナリオを検討する．
37	misalignment	ずれ，不整合	Generate a Misalignment dataset that is a simulation of possible malicious applications.	起こりうる悪意のあるアプリケーションのシミュレーションである不整合データセットを生成する．
38	simulation	シミュレーション	...that is a simulation of possible malicious applications.	...それは起こりうる悪意のあるアプリケーションのシミュレーションである．
39	malicious	悪意のある	...a simulation of possible malicious applications.	...起こりうる悪意のあるアプリケーションのシミュレーション．
40	unaligned	調整されていない	...potential risks of an unaligned autonomous agent system.	...調整されていない自律エージェントシステムの潜在的なリスク．
41	comprehend	理解する	Enabling them to comprehend and react to human language.	彼らが人間の言語を理解し，反応できるようにする．
42	enhance	強化する	...can potentially enhance the development of more advanced language models.	...より高度な言語モデルの開発を強化する可能性がある．
43	outperform	上回る	...outperform those generated in a single shot by gpt-3.5-turbo.	...gpt-3.5-turbo によるシングルショットで生成されたものを上回る．

44	emergence	出現，（ここでは）創発	We also study knowledge emergence in LLMs.	LLM における知識の創発についても研究する．
45	fine-tuning	微調整	...by fine-tuning LLaMA on progressively growing datasets.	...段階的に増加するデータセットで LLaMA を微調整することによって．
46	benchmark	指標，ベンチマーク	...through benchmarking our final model on HumanEval.	...HumanEval で最終モデルをベンチマークすることによって．
47	competitive	競争力のある，（ここでは）匹敵する	...we show competitive pass@k scores with LLaMa-7B.	...LLaMa-7B と遜色のない pass@k スコアを示す．
48	adhere	遵守する	Al systems adhere to their intended goals.	AI システムは意図された目標を遵守する．
49	descriptive	記述的な	...provides a detailed description to make the idea specific.	...アイデアを具体的にするための詳細な記述を提供する．
50	instantiate	具体化する，例示する	The role-playing session will be instantiated from an idea.	ロールプレイングセッションはアイデアから具体化される．
51	designate	指定する	...only to designate the potential roles.	...潜在的な役割を指定するだけでよい．
52	interact	相互作用する	Engaging in interactive planning to determine feasible steps.	実行可能なステップを決定するための対話的な計画に関与する．

53	feasible	実行可能な	...to determine feasible steps for the AI assistant to execute.	...AI アシスタントが実行するための実行可能なステップを決定する.
54	historical	過去の	...takes the historical conversation message set.	...過去の会話メッセージセットを受け取る.
55	termination	終了	...communication protocols, termination conditions, and constraints.	...通信プロトコル，終了条件，および制約.
56	protocol	プロトコル，規約	...communication protocols, termination conditions.	...通信プロトコル，終了条件.
57	constraint	制約	...termination conditions, and constraints or requirements.	...終了条件，および制約や要件.
58	deviation	逸脱	...avoiding any deviation from the structure of the conversation.	...会話の構造からの逸脱を避ける.
59	symmetry	対称性	...strive to maintain as much symmetry as possible.	...可能な限り対称性を維持するよう努める.
60	sophisticated	洗練された	...develop an increasingly sophisticated understanding of these domains.	...これらの領域に対するますます洗練された理解を深める.